

Дифракционная нейронная сеть

Акинжала Родион
Ибрагимова Ксения

Группа: Б05-308

Введение

Развитие методов машинного обучения приводит к росту вычислительной нагрузки, особенно в задачах, связанных с глубокими нейросетями. Одной из альтернатив традиционным цифровым архитектурам являются оптические нейросети, в частности, дифракционные нейронные сети (D2NN), в которых обработка информации осуществляется за счёт дифракции света на последовательности фазовых масок.

В отличие от обычных нейросетей, D2NN выполняет вычисления физически: фазовые маски модифицируют волновой фронт, а свободное распространение между ними реализует линейное преобразование. Это позволяет обрабатывать данные параллельно и с высокой энергоэффективностью.

В данной работе исследуется предложенный в [1] подход к построению D2NN. Мы формулируем физическую модель, основанную на уравнении Гельмгольца и методе Релея, а также реализуем обучение сети для численного подбора оптимальных фазовых масок.




Рис. 1: Фазовые маски дифракционной нейронной сети, в эксперимент UCLA [1].

Описание модели

Дифракционная нейронная сеть (D2NN) состоит из последовательности N плоских фазовых масок, расположенных вдоль оптической оси и разделённых промежутками свободного распространения когерентного света. Входное поле $A_0(x, y)$, заданное в начальной плоскости, последовательно претерпевает фазовую модуляцию и дифракционное распространение.




Рис. 2: Схема установки

Каждый фазовый слой m описывается фазовой функцией $\varphi_m(x, y)$ и реализует преобразование поля вида

$$A_m^+(x, y) = A_m(x, y) \cdot e^{i\varphi_m(x, y)},$$

где $A_m(x, y)$ — поле перед m -й маской, а $A_m^+(x, y)$ — поле после маски. После прохождения маски поле распространяется на фиксированное расстояние d_m , что соответствует переходу к следующему слою.

Таким образом, каждый слой D2NN выполняет операцию **фазовой модуляции**, а каждый промежуток между слоями — **свободное дифракционное распространение**. В итоге получаем эквивалент линейного преобразования, аналогичного действиям весов в традиционной нейросети. В результате, на выходной плоскости формируется распределение интенсивности света, по которому осуществляется распознавание входного сигнала.

Метод Релея для D2NN

Рассмотрим распространение монохроматического когерентного волнового поля в наборах плоских фазовых масок, разделённых однородной средой. Введём комплексную амплитуду поля $A(x, y, z)$ так, что реальное поле имеет вид

$$E(\mathbf{r}, t) = \Re\{A(x, y, z)e^{-i\omega t}\}.$$

В однородной среде с постоянным n эта амплитуда удовлетворяет волновому уравнению:

$$\nabla^2 A(x, y, z) - \frac{n^2}{c^2} \frac{\partial^2 A}{\partial t^2} = 0.$$

Подставляя гармоническую временную зависимость $e^{-i\omega t}$, получаем уравнение Гельмгольца:

$$\nabla^2 A(x, y, z) + k^2 A(x, y, z) = 0,$$

где $k = \omega n/c = 2\pi n/\lambda$ — волновое число в среде.

Для решения уравнения Гельмгольца применим метод Рэлея, основанный на представлении произвольного поля в виде суперпозиции плоских волн. Это достигается с помощью двумерного преобразования Фурье по поперечным координатам x и y в плоскости $z = 0$:

$$\tilde{A}(k_x, k_y; 0) = \iint_{-\infty}^{+\infty} A(x, y, 0) e^{-i(k_x x + k_y y)} dx dy.$$

Каждая плоская волна вида $e^{i(k_x x + k_y y)}$ распространяется вдоль оси z с фазовым множителем $e^{ik_z z}$, где продольная компонента волнового вектора задаётся следующим соотношением:

$$k_z = \sqrt{k^2 - k_x^2 - k_y^2}.$$

Таким образом, поле на расстоянии z выражается через обратное преобразование Фурье:

$$A(x, y, z) = \frac{1}{(2\pi)^2} \iint \tilde{A}(k_x, k_y; 0) e^{i(k_x x + k_y y + k_z z)} dk_x dk_y.$$

Это решение уравнения Гельмгольца удобно численно реализуется с помощью Быстрого Преобразования Фурье (FFT).

Расчёт поля системы

Алгоритм расчёта амплитуды поля $A(x, y, z)$ в плоскости, удалённой от источника на расстояние z , включает три последовательных этапа:

1. **Преобразование Фурье:** Исходное поле в плоскости $z = 0$ представляется в спектральной области:

$$\tilde{A}(k_x, k_y; 0) = \mathcal{F}\{A(x, y, 0)\}.$$

2. **Модификация спектра:** Каждая плоская волна распространяется вдоль оси z с фазовым множителем $e^{ik_z z}$, где

$$k_z = \sqrt{k^2 - k_x^2 - k_y^2}.$$

Таким образом, спектральное представление поля на расстоянии z записывается как

$$\tilde{A}(k_x, k_y; z) = \tilde{A}(k_x, k_y; 0) \cdot e^{ik_z z}.$$

3. **Обратное преобразование Фурье:** Для восстановления поля в пространственной области применяется обратное преобразование:

$$A(x, y, z) = \mathcal{F}^{-1}\{\tilde{A}(k_x, k_y; z)\}.$$

Моделирование D2NN

В дифракционной нейронной сети поле $A_0(x, y)$ проходит через N фазовых масок и свободные участки распространения. Каждая маска описывается фазовой функцией $\varphi_m(x, y)$ и реализует преобразование:

$$A_m^+(x, y) = A_m(x, y) e^{i\varphi_m(x, y)}.$$

где $A_m(x, y)$ — поле до m -й маски, а $A_m^+(x, y)$ — поле непосредственно после модуляции.

Между слоями поле распространяется на расстояние d_m , модифицируясь согласно методу углового спектра. Последовательное применение фазовых масок и распространения приводит к выходному полю:

$$A_{\text{out}}(x, y) = \mathcal{F}^{-1} \left\{ \mathcal{F} \left[\dots \mathcal{F} \left(A_0(x, y) e^{i\varphi_1(x, y)} \right) e^{ik_z d_1} \dots e^{i\varphi_N(x, y)} \right] e^{ik_z d_N} \right\}.$$

Формирование начального фазового фронта

Для подачи изображения в сеть оно преобразуется в комплексное поле с фазовой модуляцией. Нормированное изображение $I(x, y) \in [0, 0.5]$ интерпретируется как фазовый профиль входного поля:

$$A_0(x, y) = \exp(2\pi i I(x, y)).$$




Рис. 3: Фазовые распределения, подаваемые на вход D2NN.

Для согласования с размером апертуры выполняется масштабирование и дополнение нулями по краям. Это обеспечивает когерентное возбуждение с заданным фазовым распределением. Примеры полученных фазовых фронтов показаны на рисунке 7.

Архитектура сети

Модель состоит из последовательности фазовых масок и завершается детекторной плоскостью. Входное поле имеет фиксированную амплитуду; обучаемыми параметрами являются фазовые профили $\Phi_k(x, y)$, где k — номер слоя. Расстояние между масками задано как $z = 3$ см и остаётся постоянным.

Для датасета MNIST использовалась архитектура из шести фазовых слоёв размером 200×200 , а для EMNIST — из пяти фазовых масок размером 120×120 . Размер одного пикселя составляет $\text{pixel_size} = 100 \times 10^{-6}$ м, а длина волны, на которой происходит обучение, равна $\lambda = 0.75 \times 10^{-3}$ м.

Реализация

Для численного моделирования дифракционной нейронной сети реализована архитектура в среде **TensorFlow** с использованием пользовательских слоёв. Каждый фазовый слой задаётся классом **Diffraction_Layer**, в котором фазовый профиль представлен как обучаемый параметр $\Phi(x, y)$, а распространение поля моделируется методом углового спектра. Вычисления производятся в комплексной области с применением FFT и фазового множителя $e^{ik_z z}$, зависящего от длины волны и пространственных частот.

Распространение между слоями реализовано в виде отдельного класса **Propagation**, использующего ту же модель дифракции, но без обучаемых параметров. Завершающий слой **Detector** агрегирует амплитуду поля в фиксированную сетку детекторов и возвращает вектор признаков, соответствующий числу классов.

Архитектура сети собирается с помощью функции `get_D2NN_model()`, которая формирует последовательность фазовых масок, слой свободного распространения и детектор.

Функция потерь и оптимизация

Классификация объектов осуществляется на основе анализа интегральной интенсивности света, регистрируемой в непересекающихся областях детекторной плоскости. Для датасета MNIST используется 10 таких областей, что соответствует количеству классов цифр, а для выбранного подмножества букв из датасета EMNIST — 12 областей.

Оптимизация параметров модели проводится с помощью алгоритма Adam при минимизации функции потерь категориальной кросс-энтропии (`categorical_crossentropy`).

Динамика обучения

Прогресс обучения на уровне батчей




Рис. 4: Прогресс обучения модели на датасете MNIST на уровне батчей

Динамика обучения D2NN модели




Рис. 5: Динамика обучения модели на датасете MNIST

На рис. 4 и 5 представлены кривые обучения, отражающие динамику точности классификации и величины потерь в процессе оптимизации. В результате обучения модель достигла точности классификации более 86%.

Полученные результаты демонстрируют, что предложенная дифракционная нейронная сеть успешно научилась выделять характерные пространственные признаки символов в проходящем световом поле. Это подтверждает эффективность использования последовательности фазовых модуляторов для задач оптической классификации изображений.

Расчёт карт высот для печати фазовых элементов

Для последующего 3-D прототипирования фазовые распределения переводятся в реальные высоты по формуле

$$h(x, y) = \frac{\lambda \Phi(x, y)}{2\pi \Delta n}, \quad \Delta n = n_{\text{mat}} - n_{\text{air}}. \quad (1)$$

В расчётах использованы следующие характеристики системы:


$$\lambda = 0.75 \text{ mm};$$

$$n_{\text{mat}} = 1.7227 \quad (\text{материал — фотополимер VeroBlackPlus RGD875});$$

$$n_{\text{air}} = 1.0003;$$


Отсюда $\Delta n = 0.7224$

На рис. 6 видно, что первые два слоя задают крупномасштабную фокусировку, в то время как последние формируют тонкие «гребни», отбирающие пространственные гармоники, специфичные для каждой буквы.



(a) Визуализация дифракционных слоёв

3D-визуализация с общей цветовой шкалой



(b) 3D визуализация дифракционных слоёв

Рис. 6: Фазовые маски

Эволюция интенсивности вдоль оптической оси

На рис. 7 приведены тепловые карты интенсивности $I(x, y)$ после каждого слоя. После первой маски свет лишь слегка концентрируется в центральной области; на детекторной плоскости яркие максимумы попадают в назначенные им окна.




Рис. 7: Распределения интенсивности после каждого слоя




Рис. 8: Распределения интенсивности после каждого слоя

Оценка устойчивости к изменению параметров

Для практической реализации дифракционной нейросети важно определить, как отклонения ключевых физических параметров влияют на точность классификации. Это позволяет задать допустимые пределы погрешностей при изготовлении и настройке системы. Поэтому в данном разделе проводится анализ чувствительности модели к изменению длины волны и фазового шума масок.

Устойчивость к изменению длины волны

Изначально обучение нейросети проводилось для фиксированной длины волны $\lambda = 0.75 \text{ mm}$, после чего на уже обученной системе проводилось моделирование с различными длинами волн в окрестности этого значения.




Рис. 9: Зависимость точности классификации от длины волны.

Как видно из рисунка 9, при изменении длины волны на $\pm 2\%$ от номинального значения точность модели снижается незначительно и остается выше 80%. Это свидетельствует об определённой устойчивости системы к спектральным флуктуациям источника.

Таким образом, физический эксперимент может быть реализован с допуском по длине волны порядка $\pm 0.015 \text{ mm}$ без существенного ухудшения качества распознавания. Это существенно упрощает требования к источнику когерентного излучения при реализации D2NN в лабораторных условиях.

Ниже представлены визуализации интенсивности выходного поля для различных значений λ на примере буквы i:




Рис. 10: Распределение интенсивности на детекторе при различных длинах волн

Устойчивость к фазовому шуму

Для анализа устойчивости дифракционной нейросети к фазовым искажениям проведена серия экспериментов с случайными возмущениями фазовых профилей масок, моделирующими погрешности 3D-принтера. В каждый фазовый слой $\varphi(x, y)$ добавлялся нормально распределённый шум:

$$\delta(x, y) \sim \mathcal{N}(0, \sigma^2(x, y)), \quad \sigma(x, y) = \alpha \cdot |\varphi(x, y)|,$$

$$\varphi'(x, y) = (\varphi(x, y) + \delta(x, y)) \bmod 2\pi,$$

где $\alpha \in [0, 1]$ — параметр, определяющий относительный уровень шума. Для каждого значения α проводилось по 10 запусков с независимыми реализациями возмущений, после чего рассчитывалась средняя точность классификации на тестовой выборке и соответствующее стандартное отклонение.




Рис. 11: Зависимость точности классификации от изменения фазы слоев.