

Инициализация дифракционной нейронной сети методом Гершберга-Сакстона

Акинжала Родион, Ибрагимова Ксения

Московский физико-технический институт
68-я Всероссийская научная конференция МФТИ

Проблема: Рост вычислительной нагрузки нейронных сетей стимулирует поиск новых вычислительных архитектур.

Решение — оптические вычисления:

- Обработка информации посредством физического распространения света
- Высокая энергоэффективность и параллелизм

D2NN — дифракционная нейронная сеть:

Классификация через дифракцию когерентного излучения на последовательности фазовых масок. Обучаемые параметры — фазовые профили масок, оптимизируемые градиентным спуском.

Ключевой вопрос: Как правильно инициализировать фазовые профили масок перед обучением?

Цель: Разработка и исследование метода инициализации D2NN на основе алгоритма Гершберга–Сакстона.


Архитектура D2NN

D2NN состоит из:

- N плоских **фазовых масок**
- Разделены промежутками свободного распространения
- На выходе — пространственное распределение интенсивности и детектор

Операции каждого слоя:

- 1 Фазовая модуляция
- 2 Свободное дифракционное распространение



Каждый фазовый слой m описывается фазовой функцией $\varphi_m(x, y)$ и реализует преобразование:

$$A_m^+(x, y) = A_m(x, y) \cdot e^{i\varphi_m(x, y)}$$

где $A_m(x, y)$ — поле *перед* маской, $A_m^+(x, y)$ — поле *после*.

Результирующее преобразование:

- Каждый слой: **фазовая модуляция**
- Промежуток между слоями: **свободное дифракционное распространение**
- Эквивалент весовых коэффициентов в традиционной нейросети

Волновое уравнение Гельмгольца

Монохроматическое волновое поле описывается комплексной амплитудой:

$$E(\mathbf{r}, t) = \Re\{A(x, y, z)e^{-i\omega t}\}$$

Амплитуда в однородной среде удовлетворяет уравнению Гельмгольца:

$$\nabla^2 A + k^2 A = 0, \quad k = \frac{2\pi n}{\lambda}$$

Решение представляется суперпозицией плоских волн. Для волны $e^{i(k_x x + k_y y)}$ продольная компонента волнового вектора:

$$k_z = \sqrt{k^2 - k_x^2 - k_y^2}$$

Метод Рэлея: распространение углового спектра

Шаг 1. Преобразование Фурье в плоскости $z = 0$:

$$\tilde{A}(k_x, k_y; 0) = \iint A(x, y, 0) e^{-i(k_x x + k_y y)} dx dy$$

Шаг 2. Фазовый набег при распространении на расстояние z :

$$\tilde{A}(k_x, k_y; z) = \tilde{A}(k_x, k_y; 0) \cdot e^{ik_z z}$$

Шаг 3. Обратное преобразование Фурье:

$$A(x, y, z) = \frac{1}{(2\pi)^2} \iint \tilde{A}(k_x, k_y; z) e^{i(k_x x + k_y y)} dk_x dk_y$$

Численно реализуется с помощью быстрого преобразования Фурье (FFT)

Математическая формулировка:

$$A_{\text{out}} = \mathcal{P}_{d_N} \circ e^{i\varphi_N} \circ \mathcal{P}_{d_{N-1}} \circ \dots \circ e^{i\varphi_1} \circ \mathcal{P}_{d_1} \{A_{\text{in}}\}$$

где $\mathcal{P}_d$ — оператор свободного распространения ASP (метод Рэлея), $e^{i\varphi_m}$ — фазовая модуляция на слое m .

Выходной сигнал:

$$I(x, y) = |A_{\text{out}}(x, y)|^2$$

Детектор регистрирует пространственное распределение интенсивности и преобразует его в вектор классификационных оценок (логиты).

Параметры модели: Фазовые профили $\{\varphi_1, \dots, \varphi_N\}$ — обучаемые параметры, эквивалентные весам традиционной нейросети. Расстояния между слоями $\{d_1, \dots, d_{N-1}\}$ — фиксированные геометрические параметры.


Функция потерь:

$$\mathcal{L} = - \sum_{k=1}^C y_k \log(p_k)$$

где y_k — one-hot закодированный истинный класс, p_k — предсказанная вероятность через softmax от логитов детектора.

Процесс обучения:

- 1 Детектор выдает логиты:
 $\text{logit}_k = \text{mean}(|A_{\text{out}}|^2)$ в регионе k
- 2 Softmax преобразует в вероятности
- 3 Adam оптимизатор обновляет фазовые профили $\{\varphi_1, \dots, \varphi_N\}$



Динамика потерь и точности
на валидации

Инициализация фазовых масок: алгоритм Гершберга-Сакстона

Мотивация:

Вместо инициализации Xavier использовать физически осмысленное начальное приближение.


Функция потерь:

$$E^{(k)} = |||B^{(k)}| - |A_{\text{out}}|||_2^2$$


Целевое распределение:

Гауссиан обеспечивает концентрацию энергии в центре:


$$A_{\text{target}} = \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)$$



Эволюция алгоритма Гершберга-Сакстона



Эволюция алгоритма Гершберга-Сакстона



Сходимость алгоритма Гершберга–Сакстона (1/2)

Лемма. Для $k_\rho \leq k$: $|e^{ik_z z}| = 1$, поэтому по теореме Парсевала
 $\|\text{ASP}[X] - \text{ASP}[Y]\| = \|X - Y\|$

Теорема. $E_{k+1} \leq E_k$, $E_k = \sum_n (|B^{(k)}[n]| - |A_{\text{target}}[n]|)^2$

Шаг 1. Покажем, что $\tilde{B}^{(k)}$ — ближайшая точка множества $\mathcal{C}_2 = \{E : |E[n]| = |A_{\text{target}}[n]|\}$ к $B^{(k)}$.

Расстояние от $B^{(k)}[n]$ до произвольной точки $r_n e^{i\theta_n} \in \mathcal{C}_2$:

$$|B^{(k)}[n] - r_n e^{i\theta_n}|^2 = |B^{(k)}[n]|^2 + r_n^2 - 2r_n |B^{(k)}[n]| \cos(\theta_n - \arg B^{(k)}[n])$$

минимально при $\theta_n = \arg B^{(k)}[n]$ — именно так задаётся $\tilde{B}^{(k)}$.

Поскольку фазы $B^{(k)}$ и $\tilde{B}^{(k)}$ совпадают: $\|B^{(k)} - \tilde{B}^{(k)}\|^2 = E_k$

Сходимость алгоритма Гершберга–Сакстона (2/2)

Шаг 2: убыль ошибки $E_{k+1} \leq E_k$.

(а) Так как $|\tilde{B}^{(k)}[n]| = |A_{\text{target}}[n]|$, из неравенства треугольника $||z_1| - |z_2|| \leq |z_1 - z_2|$:

$$E_{k+1} \leq \|B^{(k+1)} - \tilde{B}^{(k)}\|^2$$

(б) $A^{(k+1)}$ есть проекция $\tilde{A}^{(k)}$ на $\mathcal{C}_1 = \{A : |A[n]| = |A_{\text{in}}[n]|\}$ (тот же аргумент, что в шаге 1, применённый к входной плоскости). Поскольку $A^{(k)} \in \mathcal{C}_1$:

$$\|A^{(k+1)} - \tilde{A}^{(k)}\| \leq \|A^{(k)} - \tilde{A}^{(k)}\|$$

(в) Собираем цепочку, используя изометрию ASP и шаги 1, б:

$$E_{k+1} \stackrel{(a)}{\leq} \|B^{(k+1)} - \tilde{B}^{(k)}\|^2 \stackrel{\text{изом.}}{=} \|A^{(k+1)} - \tilde{A}^{(k)}\|^2 \stackrel{(б)}{\leq} \|A^{(k)} - \tilde{A}^{(k)}\|^2 \stackrel{\text{изом.}}{=} \|B^{(k)} - \tilde{B}^{(k)}\|^2 \stackrel{\text{ш.1}}{=} E_k$$

□

Замечание: на каждой итерации ошибка фокусировки монотонно убывает. Глобальная сходимость не гарантируется: алгоритм может стагнировать в локальном минимуме.

Влияние инициализации на обучение





Две стратегии инициализации:

- 1 **Random:** Случайная фаза без физического смысла
- 2 **G-S Init:** Фазовые маски оптимизированы алгоритмом Гершберга-Сакстона
Каждая маска уже действует как фокусирующая линза

Результат: G-S инициализация:

- более высокая итоговая точность при схожей скорости сходимости
- Финальная точность выше

Сравнение обучения



Фазовые слои

Толщина:

Фазовые профили кодируют информацию модели. Для физической можно рассчитать толщину:

$$h(x, y) = \frac{\lambda \Phi(x, y)}{2\pi(\Delta n)}$$

Система параметров:

Длина волны

$\lambda = 0.75$ мм


Показатель (материал)

$n_{\text{mat}} = 1.7227$


Показатель (воздух)

$n_{\text{air}} = 1.0003$

Материал: фотополимер VeroBlackPlus
RGD875




Проекции фазовых профилей каждого слоя



Фазовые слои D2NN

Эволюция интенсивности вдоль оптической оси



Распределение интенсивности $I(x, y)$ после каждого слоя


Анализ устойчивости: длина волны

Задача: Определить допустимые отклонения физических параметров без потери точности

Результаты:


- Обучение: $\lambda = 0.75$ мм
- Тестирование: λ в диапазоне $\pm 2\%$
- Точность остается выше 80%

Вывод: Система устойчива к спектральным флуктуациям источника



Зависимость точности от λ

Анализ устойчивости: длина волны



Распределение интенсивности на детекторе

Анализ устойчивости: фазовый шум

Модель шума:

Нормально распределённые возмущения
фазовых профилей

$$\delta(x, y) \sim \mathcal{N}(0, \sigma^2(x, y))$$

$$\sigma = \alpha \cdot |\varphi(x, y)|$$

где $\alpha \in [0, 1]$ — параметр уровня шума.



Точность при разных уровнях шума

Численная модель D2NN:

- Фазовые профили масок — обучаемые параметры, оптимизируемые градиентным спуском
- Свободное распространение (ASP) между масками реализует связи между нейронами оптически

Инициализация методом Гершберга–Сакстона:

- Физически осмысленное начальное приближение вместо случайного или инициализации Xavier
- Доказана монотонная убыль ошибки фокусировки на каждой итерации
- GS-инициализация объединяет итерационную оптимизацию и градиентный спуск в единый процесс

Результаты на датасете MNIST:

- Итоговая точность: 83.55% против 82.95% при случайной инициализации
- Более быстрый выход на эффективный режим обучения

Спасибо за внимание!

Акинжала Родион