

Устойчивость дифракционных нейронных сетей к шумам различного происхождения

Ибрагимова Ксения, Акинжала Родион

Московский физико-технический институт

Проблема: Традиционные нейросети требуют значительных энергозатрат и вычислительных ресурсов, что ограничивает масштабируемость для задач обработки данных в реальном времени.

Решение — оптические вычисления:

- Энергоэффективность (исключение электронных потерь)
- Пропускная способность на уровне скорости света

D2NN (Diffraction Deep Neural Network):

Оптическая реализация нейросети через архитектуру фазовых модуляторов и свободного распространения света. Фазовые слои кодируют параметры модели, распространение реализует нелинейную трансформацию данных.

Цель: Анализ практической реализации и устойчивости D2NN.


Архитектура D2NN

D2NN состоит из:

- N плоских **фазовых масок**
- Разделены промежутками свободного распространения
- На выходе — пространственное распределение интенсивности и детектор

Операции каждого слоя:

- 1 Фазовая модуляция
- 2 Свободное дифракционное распространение



Каждый фазовый слой m описывается фазовой функцией $\varphi_m(x, y)$ и реализует преобразование:

$$A_m^+(x, y) = A_m(x, y) \cdot e^{i\varphi_m(x, y)}$$

где $A_m(x, y)$ — поле *перед* маской, $A_m^+(x, y)$ — поле *после*.

Результирующее преобразование:

- Каждый слой: **фазовая модуляция**
- Промежуток между слоями: **свободное дифракционное распространение**
- Эквивалент весовых коэффициентов в традиционной нейросети

Волновое уравнение Гельмгольца

Монохроматическое волновое поле описывается комплексной амплитудой:

$$E(\mathbf{r}, t) = \Re\{A(x, y, z)e^{-i\omega t}\}$$

Амплитуда в однородной среде удовлетворяет уравнению Гельмгольца:

$$\nabla^2 A + k^2 A = 0, \quad k = \frac{2\pi n}{\lambda}$$

Решение представляется суперпозицией плоских волн. Для волны $e^{i(k_x x + k_y y)}$ продольная компонента волнового вектора:

$$k_z = \sqrt{k^2 - k_x^2 - k_y^2}$$

Метод Рэлея: распространение углового спектра

Шаг 1. Преобразование Фурье в плоскости $z = 0$:

$$\tilde{A}(k_x, k_y; 0) = \iint A(x, y, 0) e^{-i(k_x x + k_y y)} dx dy$$

Шаг 2. Фазовый набег при распространении на расстояние z :

$$\tilde{A}(k_x, k_y; z) = \tilde{A}(k_x, k_y; 0) \cdot e^{ik_z z}$$

Шаг 3. Обратное преобразование Фурье:

$$A(x, y, z) = \frac{1}{(2\pi)^2} \iint \tilde{A}(k_x, k_y; z) e^{i(k_x x + k_y y)} dk_x dk_y$$

Численно реализуется с помощью быстрого преобразования Фурье (FFT)

Математическая формулировка:

$$A_{\text{out}} = \mathcal{P}_{d_N} \circ e^{i\varphi_N} \circ \mathcal{P}_{d_{N-1}} \circ \dots \circ e^{i\varphi_1} \circ \mathcal{P}_{d_1} \{A_{\text{in}}\}$$

где $\mathcal{P}_d$ — оператор свободного распространения (метод Рэлея), $e^{i\varphi_m}$ — фазовая модуляция на слое m .

Выходной сигнал:

$$I(x, y) = |A_{\text{out}}(x, y)|^2$$

Детектор регистрирует пространственное распределение интенсивности и преобразует его в вектор классификационных оценок (логиты).

Параметры модели: Фазовые профили $\{\varphi_1, \dots, \varphi_N\}$ — обучаемые параметры, эквивалентные весам традиционной нейросети. Расстояния между слоями $\{d_1, \dots, d_{N-1}\}$ — фиксированные геометрические параметры.


Функция потерь:

$$\mathcal{L} = - \sum_{k=1}^C y_k \log(p_k)$$

где y_k — one-hot закодированный истинный класс, p_k — предсказанная вероятность через softmax от логитов детектора.

Процесс обучения:

- 1 Детектор выдает логиты:
 $\text{logit}_k = \text{mean}(|A_{\text{out}}|^2)$ в регионе k
- 2 Softmax преобразует в вероятности
- 3 Adam оптимизатор обновляет фазовые профили $\{\varphi_1, \dots, \varphi_N\}$



Динамика потерь и точности
на валидации

Фазовые слои

Толщина:

Фазовые профили кодируют информацию модели. Для физической можно рассчитать толщину:

$$h(x, y) = \frac{\lambda \Phi(x, y)}{2\pi(\Delta n)}$$

Система параметров:

Длина волны

$\lambda = 0.75$ мм


Показатель (материал)

$n_{\text{mat}} = 1.7227$


Показатель (воздух)

$n_{\text{air}} = 1.0003$

Материал: фотополимер VeroBlackPlus
RGD875




Проекции фазовых профилей каждого слоя



Фазовые слои D2NN

Эволюция интенсивности вдоль оптической оси



Распределение интенсивности $I(x, y)$ после каждого слоя

Фазовое кодирование

$$A_{\text{in}}(x, y) = e^{i\phi(x, y)}$$

Амплитудное кодирование

$$A_{\text{in}}(x, y) = a(x, y)$$

Для каждого способа кодирования сравнивались:

- стандартное обучение;
- робастное обучение.

Цель: сопоставить точность и устойчивость D2NN при различных способах кодирования входа и режимах обучения.

Исследуемые характеристики:

- точность классификации;
- устойчивость к изменению длины волны;
- устойчивость к фазовым искажениям масок;
- влияние робастного обучения на устойчивость модели.

На этапе обучения в фазовые профили масок добавлялись случайные возмущения, моделирующие ошибки изготовления.

Модель:

$$\begin{aligned}\tilde{\varphi}(x, y) &= \text{mod}(\varphi(x, y) + \delta(x, y), 2\pi) \\ \delta(x, y) &\sim \mathcal{N}(0, \sigma^2(x, y)), \quad \sigma(x, y) = \alpha |\varphi(x, y)|\end{aligned}$$


α определяет интенсивность шума при обучении.

Назначение метода: уменьшить падение точности при наличии технологических дефектов фазовых масок.

Устойчивость к изменению длины волны


- максимальная точность достигается в диапазоне $\lambda \approx 0.74\text{--}0.76$ мм;
- при выходе за этот интервал точность снижается;
- робастное обучение расширяет рабочий диапазон длин волн.

Вывод: робастные модели менее чувствительны к отклонению длины волны от номинального значения.



Зависимость точности от уровня шума

Анализ устойчивости: длина волны



Распределение интенсивности на детекторе

Устойчивость к шумам изготовления


Модель возмущений:

$$\delta(x, y) \sim \mathcal{N}(0, \sigma^2(x, y)),$$

$$\sigma(x, y) = \eta |\varphi(x, y)|$$

где η — относительный уровень шума изготовления.

Результат: робастное обучение приводит к более медленному снижению точности при увеличении шума.




Зависимость точности от уровня шума

Влияние параметра робастного обучения

Для каждой архитектуры была обучена серия моделей при различных значениях параметра α .

- в диапазоне $\alpha = 0-0.04$ качество изменяется незначительно;
- при $\alpha \geq 0.05$ наблюдается снижение точности.

Вывод: умеренная робастная регуляризация улучшает качество, тогда как чрезмерное увеличение α приводит к ухудшению классификации.



Точность в зависимости от параметра α

- Исследована устойчивость D2NN к изменению длины волны и шумам изготовления фазовых масок.
- Робастное обучение уменьшает чувствительность модели к физическим возмущениям.
- Существует оптимальный диапазон параметра робастного обучения: умеренные значения улучшают устойчивость, большие — снижают точность.
- Фазовое и амплитудное кодирование входа дают близкие результаты по точности на простой задаче классификации.
- Полученные результаты могут быть использованы при проектировании оптических вычислительных систем и задании допусков на их изготовление.